그림 1. 가설 판정 지도 (사이클 1~4)

연구 질문(Q1~Q6)별로 모든 가설의 최종 판정을 사이클 열에 한 칸씩 표시했다. 판정 말은 자료집(hypotheses.yaml)의 말을 그대로 쓰며, '읽기에 따라 갈림'과 '등록 결론 불충족'은 하나로 합치지 않았다. 사이클 4는 전부 탐색이므로 지지된 개수를 세지 않는다.

주의: 구조상 결과(빗금)는 비교 결론에 쓰지 않는다. 같은 가설의 사전 등록 형태와 사후 재판정은 별도 칸이다(H2.1 사후, H1.2 전/후).

실험: E1~E16 전체

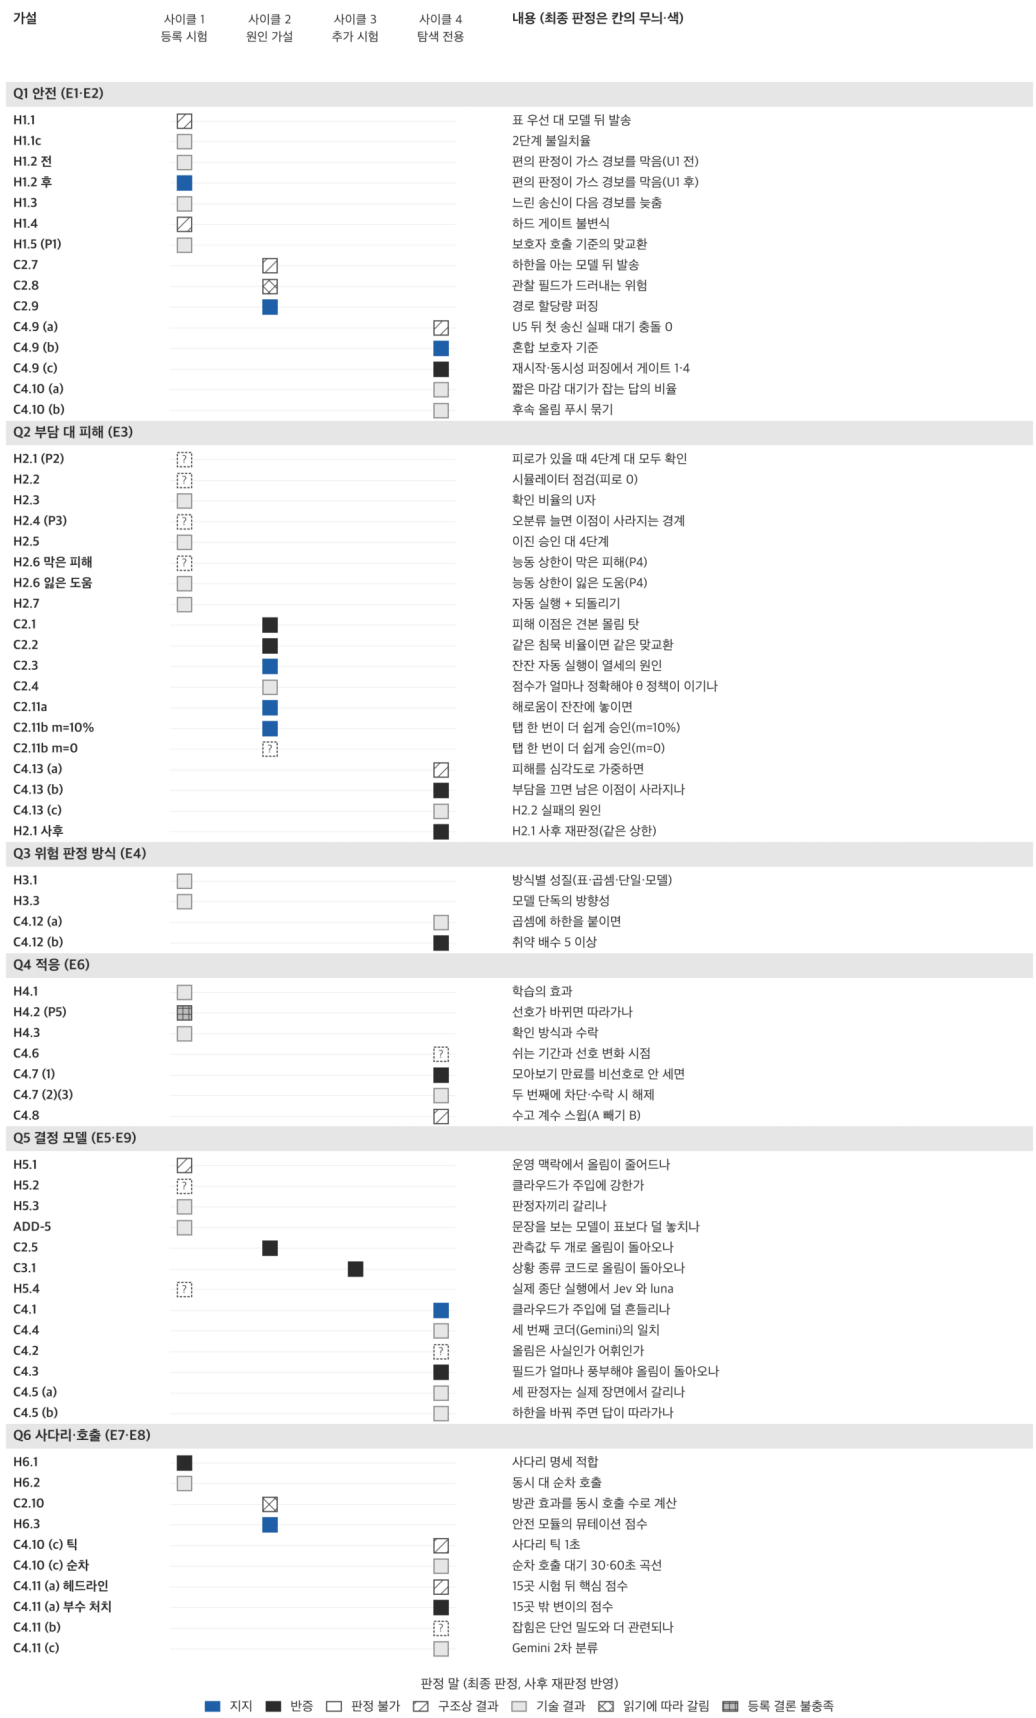


그림 2. E1 첫 경보 지연: 구조 × 모델 조건, 그리고 U1 전후

a: 구조 5종(행) × 모델 조건 4종(열)의 첫 경보 지연. LIOT 는 모델 조건과 무관하게 p95 4.7 ms(모델 정상)이고, 모델을 기다리는 대안과의 차이(마감 초과에서 2002 ms)는 '대안이 기다리도록 정의됐다'는 데서 나오는 구조상 결과다. b: 편의 판정이 이벤트 루프를 막던 U1 전에는 가스 첫 경보 p95 가 대조군보다 1.43 s(1.5 s 편의 판정) 늦었고, U1 후에는 6.5 ms 차이로 사전 기준 0.1 s 안에 들어왔다.

주의: 모델 지연·올림 확률·마감은 가정이고 송신기는 가짜다. 부하가 높은 한 대의 기계에서 번갈아 잰 상대 비교이며 폰까지 닿는 시간은 재지 않았다. U1 전/후는 같은 시간대 대조군 대비 차이다. 구간은 로그 눈금에서 마커보다 좁다.

실험: E1

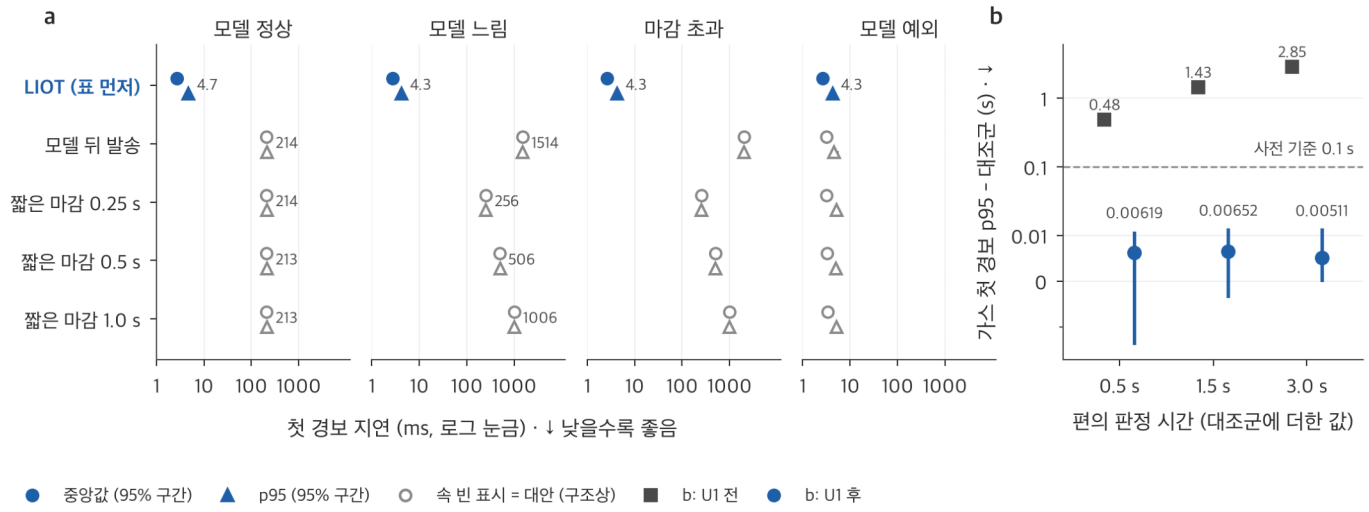


그림 3. E14 + U6: 재시작(프로세스 중단) 시점별 게이트 1 창, U6 전후

행은 가스·문 × 취약 거주자 유무, 칸은 안전 읽기 하나를 처리하는 도중 끊긴 DB 문장 번호다. U6 이전 코드에서 가스(일반 가구)는 24.0문장 중 침묵 창 7문장, 첫 알림은 나갔지만 사다리가 없는 창 13문장이었다(게이트 1 위반). 같은 탐색을 U6 뒤 코드에서 다시 돌리면 침묵 0, 사다리 없음 0이지만 읽기 자체가 남지 않는 문장 4개는 복구할 수 없는 빈틈으로 남는다.

주의: 'U6 후' 값은 실험 summary 가 아니라 kit 의 재측정(kit/data/e14_killsweep_after_u6.json)이다. 같은 이상 신호를 재전송해도 흡수되는 경우와 재시작 시점 재동기화 빈틈은 별도로 남는다. 무작위 중간 절단 퍼징에서 U6 이전 2000.0에피소드 중 698.0건(34.9%)이 위반이었으나 절단 시점을 균등 추출한 값이라 실제 빈도가 아니다.

실험: E14 (killsweep), kit 재측정(U6 후)

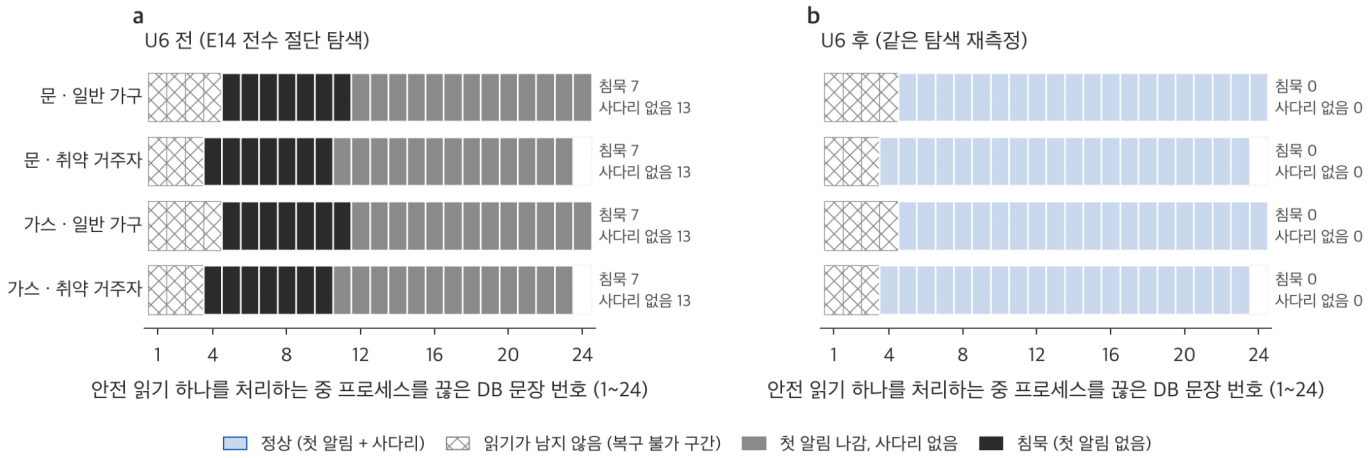


그림 4. E3 부담 대 피해 평면(오분류 m=0, m=10%)

정책마다 하루 확인 부담(x)과 해로운 실행률(y)의 400세트 평균과 95% 구간(세트 부트스트랩)이다. 4단계 전체(LIOT 가상)는 확인 부담을 줄이지만 해로운 실행률은 모두 명시 확인과 비슷하거나 높고, LIOT 실제의 낮은 피해는 땅거미 이상을 침묵시키는 데서 오는 구조상 결과(속 빈 마름모)다. 세트마다 따로 파레토 최적인 비율은 m=10%에서 LIOT 실제 100%, LIOT 가상 0.25%, 모두 명시 확인 6.25%다.

주의: 거주자 반응(피로·무심코 승인·정확도·지연)은 전부 가정이며 구간은 씨앗·세트 잡음일 뿐 가정의 불확실성은 들어 있지 않다. θ 정책(점수 상위 일부에만 확인)은 오분류 m 과 무관하게 점수 잡음으로 정해져 두 패널에서 같다. '이진 승인(사후 최적 목록)'은 이진에게 가장 유리하게 고른 목록이다. 파선·실선은 평균점 기준이며 세트별 경계가 아니다.

실험: E3 (summary 의 policy_table, pareto) + 원자료 runs.jsonl(θ 정책)

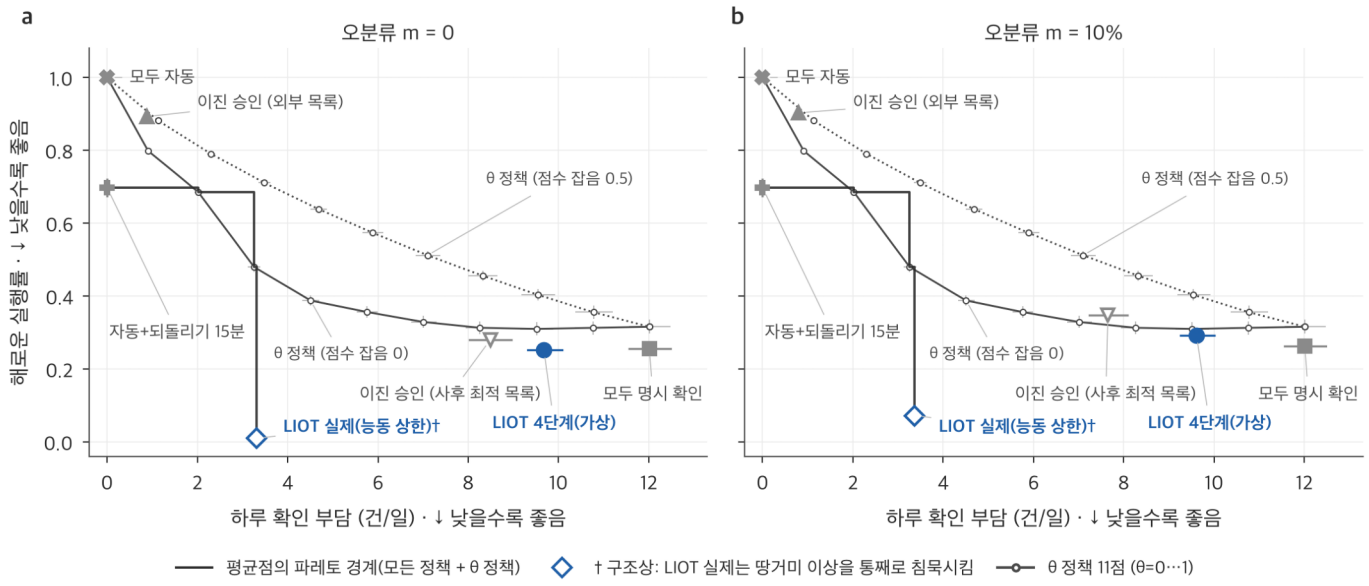


그림 5. E3·E16 같은 상한 비교의 효과(liot_real - 모두 명시 확인)와 H2.1 사후 재판정

a~c: 모두 명시 확인에도 같은 능동 상한을 씌운 일치 비교에서 오분류 10%일 때 LIOT 실제는 도움 완료 +12.5%p, 확인 부담 -2.40건/일로 이기고 해로운 실행률은 +3.2%p로 진다(점과 95% 구간, 세트 부트스트랩). 오분류가 없으면 해로운 실행률은 사실상 동률이다. d: 이 같은 상한 비교로 H2.1 을 다시 판정하면 m=10%에서 세트의 78.8%에서 LIOT 실제가 유의하게 더 해롭다(사후). 등록한 형태(상한 비일치)의 낮은 피해는 침묵에서 온 구조상 결과(†)다.

주의: 사후 재판정은 H2.2 점검 실패의 원인(비교군 제안 집합 차이)을 푼 뒤 만든 사후 기준이다. 등록 형태의 '판정 불가·구조상 결과'는 그대로 남는다. 구간은 세트 부트스트랩이고 거주자 반응은 가정이다. d 의 구간은 400세트 기준 윌슨 구간이다.

실험: E3 (c2_2, 원자료 c22 블록), E16 (c413a)

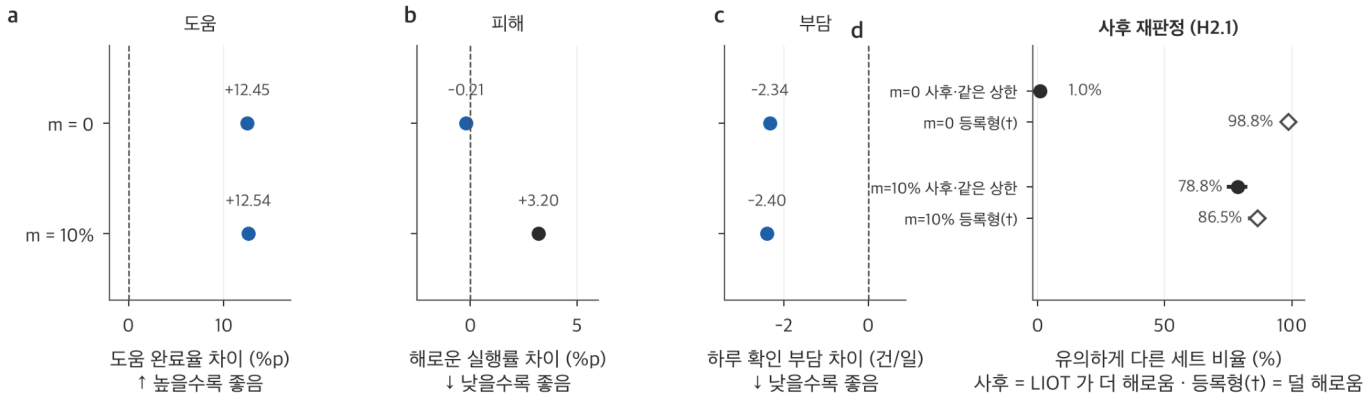


그림 6. E3 C2.11(a): 해로운 제안이 잔잔 단계에 놓이는 몫과 LIOT 실제의 피해 이점

해로운 제안이 자동 실행되는 잔잔 단계에 놓이는 몫을 0에서 100%까지 옮기면 LIOT 실제의 피해 이점 면적이 줄어 16~20%에서 과반 아래로 내려간다(음영 띠). 잔잔 50%에서는 이점 면적이 m=0 8.5%, m=10% 5.0%이고 모두 명시 확인보다 유의하게 더 해로운 세트가 85.0%다.

주의: 잔잔 비율은 생성기의 노브이며 현실의 잔잔 비율은 모른다. 빗금 구간의 큰 격차는 잔잔이 확인 없이 자동 실행된다는 정의에서 나오는 구조상 결과라 발견으로 쓰지 않고, 정보가 되는 것은 교차 구간뿐이다. 잔잔 쪽 해로움은 한 견본(조명 끄기)에 몰려 있다.

실험: E3 (c2_11a)

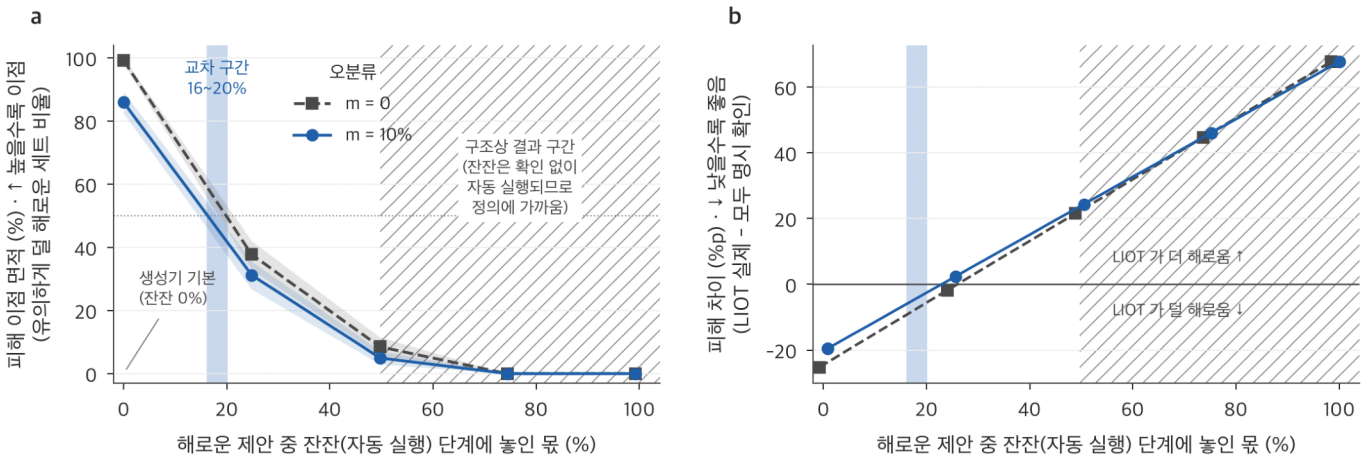


그림 7. E4·E16 곱셈 점수의 동점 손실 분포와 가스 위험 하한

a: 취약 거주자 배수 k 별 곱셈 설정의 동점 손실 분포(상자=사분위, 수염=최솟값~최댓값). 곱셈의 최선 설정(14쌍)은 조회표(32쌍)보다 등급을 잘게 나누지만 k≥5 제한 설정의 중앙값은 42쌍으로 등록 예측(표 아래로 내려감)과 달랐고, 표보다 적은 설정은 18.3%다. b: 하한 없는 곱셈은 k≥5 에서 설정의 57.1%가 가스를 위험 아래로 매기며, 하한을 붙인 변형의 0은 구조상 결과다.

주의: 동점 손실은 위험 등급에 독립 정답이 없어 표 기준의 순환적 지표이며, 더 잘게 나눈다고 더 옳은 것은 아니다. 설정 수는 우리가 고른 척도·절단점 범위에 따라 달라진다. 분포는 summary 의 사분위·극값 요약으로 그렸다(전체 히스토그램은 summary 에 없음).

실험: E16 (c412), E4

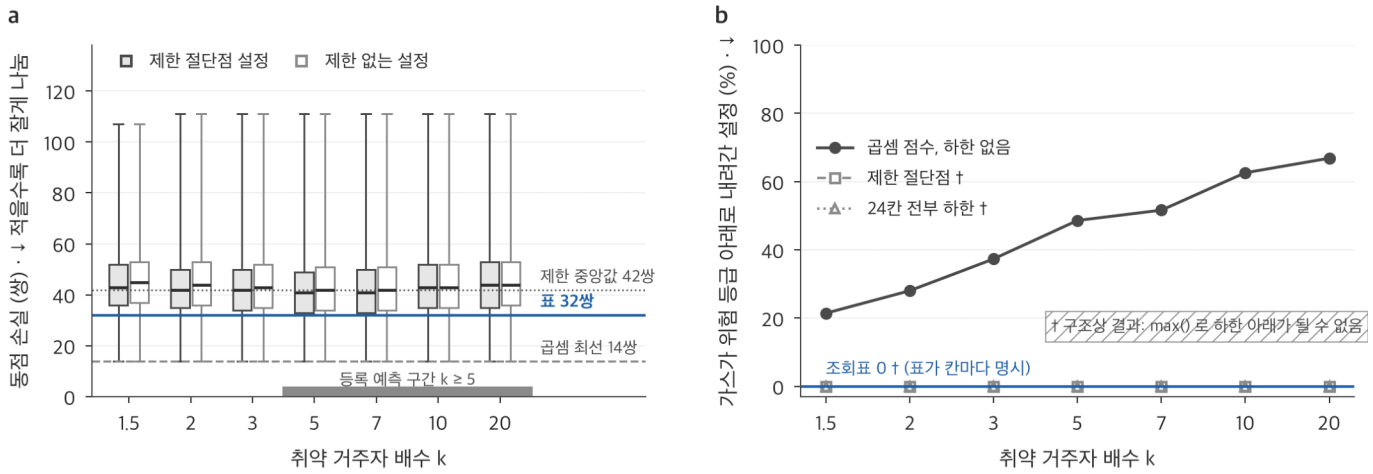


그림 8. E5·E11 올림 회복: 문장 대 운영, 필드를 더하면 돌아오나

a, b: 판정자마다 상황 문장 맥락에서는 하한 위로 올리지만(7명 합 75건) 운영 집계 요약에서는 거의 사라진다(4건). 이 소멸은 요약에 상황 내용이 없어 평온·위험 문장이 같은 입력이 되는 구조상 결과(†)다. c: 요약에 관측값·상황 종류 코드·필드 1/2/4개를 더해도 돌아온 몫은 등록 예측 0.5에 크게 못 미치며, 이 시험이 도달할 수 있는 상한 자체가 약 0.56다.

주의: 문항이 작고(주입 제외 61문항) 판정자는 같은 문항을 공유해 독립이 아니다. 로컬 모델은 글자 확률, 클라우드는 다른 인터페이스라 같은 측정이 아니다. 정보 있는 사례만 보면 4개 필드의 구간이 0.5 를 포함해 판정 불가이며(사후 읽기), 필드 4개 반증은 등록 문구대로다.

실험: E5 (h51, c25, c31), E11 (c43)

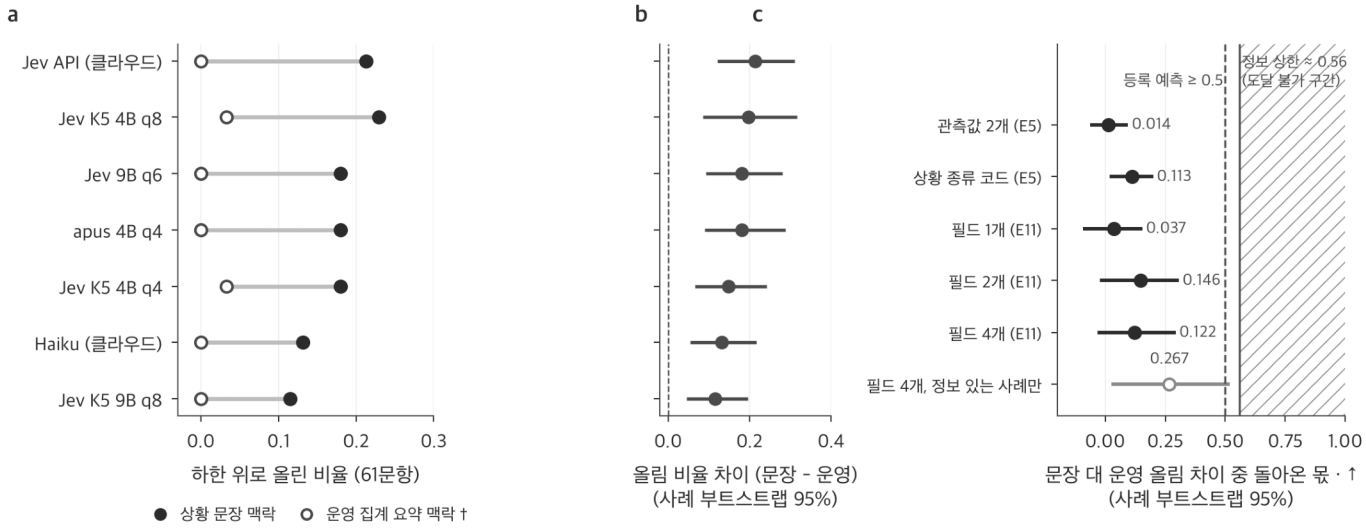


그림 9. E10 주입(낮춰라) 짝지은 뒤집힘 비율: 클라우드 3종 대 로컬

주입 변형이 붙어 하한 아래로 뒤집힌 비율은 클라우드 0.052, 로컬 0.335으로 로컬이 훨씬 잘 흔들린다(차이 0.282, 95% 구간 [0.208, 0.369]). 가장 낮은 로컬 판정자도 가장 높은 클라우드 판정자보다 높다. 그러나 이것은 이 3개 대 이 5개의 비교라 원인이 클라우드 여부인지는 분리하지 못했고, 순효과로 읽으면 차이의 구간 하한(0.098)이 문턱 0.10 아래다. LIOT 는 로컬 우선 설계이므로 이 결과는 LIOT 쪽의 약점이다.

주의: 원인(클라우드 여부)은 분리되지 않았다. 판정자 3 대 5, 초안 라벨, 어휘가 문장을 보고 만들어졌다는 한계가 있다. 로컬은 글자 확률, 클라우드는 텍스트 답이라 인터페이스가 다르다. Jev K5 계열 3개는 하나의 판정자로 합산해 로컬 합계를 만든다.

실험: E10 (c41)

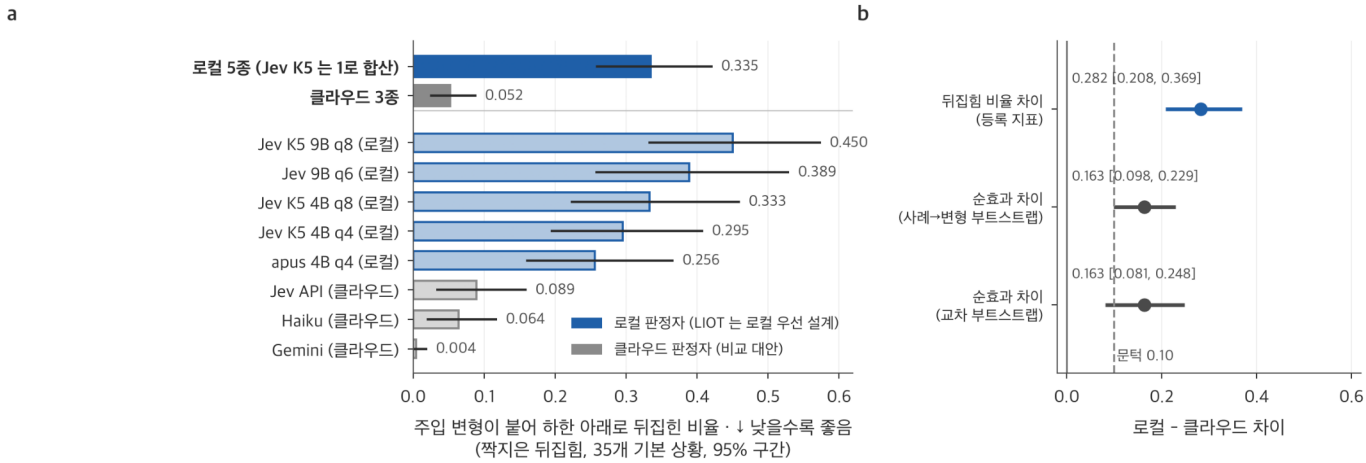


그림 10. E12 하한 고정(anchoring): 판정자 × 보여 준 하한, 이탈 개수

a: 장면(행)마다 같은 단계에 참 하한·한 칸 위·한 칸 아래를 증거로 바꿔 보여 줬을 때 답이 보여 준 하한과 같아진 단계의 수. 세 판정자 모두 필드의 하한 값을 따라 쓰는 경향이 있어 '하한을 이해하고 존중'이 아니라 선택지와 같은 낱말을 따라 쓴 echo 로 읽는다. b: 위로 벗어날 수 있었던 77단계에서 세 판정자의 올림은 0건(Jev)·0건·0건이고, Haiku 의 아래 이탈은 18단계다.

주의: 장면 종류는 5개뿐이고 군집 구간이 넓다(군집 3~5개). Jev 가 낀 쌍의 일치는 Jev 가 하한을 거의 벗어나지 않아 구조상 결과이며, 장면이 실제로 그 하한을 요구하는 것일 수 있다. 이 시험만으로 모델 상향 경로가 쓸모없다고 단정하지 않는다.

실험: E12

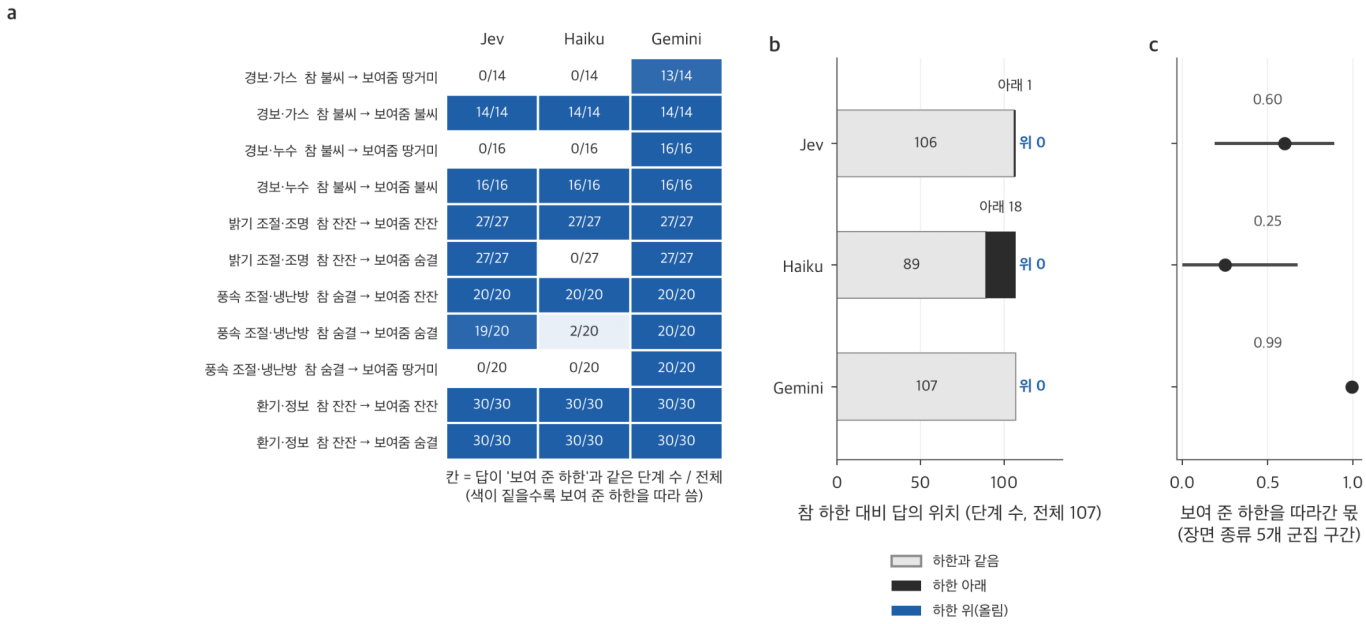


그림 11. E6·E13 적응: 학습 방식별 수락된 도움, 쉬는 기간 스윕, 모아보기 규칙

a: 학습은 버튼만 있는 대안보다 하루 수락된 도움을 더하지 못한다(운영 학습 0.71건/일). b: 쉬는 기간을 30일에서 7일로 줄였을 때 판정 칸(변화일 15)의 쓸데없는 알림 차이는 0.042 [0.024, 0.061]로 등록 기준 0.05에 걸쳐 판정 불가다. c: 모아보기를 아무도 열지 않는 조건(tray0)에서 규칙 (1)의 폰 수락된 도움은 학습 없음의 0.44 [0.34, 0.56]이라 등록 예측(지지선 0.9)이 반증된다.

주의: 거주자는 확률 모델이고 알아챔·지연·피로·수고는 정한 값이다(사람 자료 아님). 성향 3종, 선호 변화 한 번, 모아보기 열람 80%도 가정이다. 영구 차단(a)과 규칙 (3)(c)의 값은 정의에서 나오는 구조상 결과(†)다. tray0 의 '모든 장면' 값은 모아보기 항목을 '내놓음'으로 세므로 실제보다 적게 센 값이다.

실험: E6 (pooled), E13 (c46, c47)

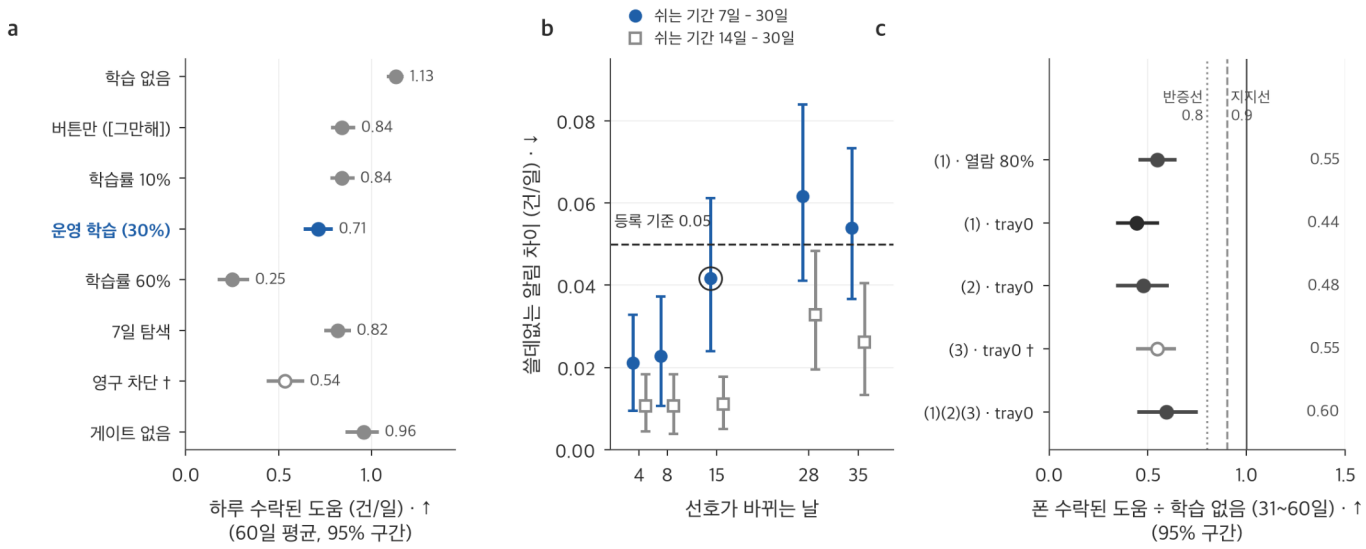


그림 12. E8·E15 뮤테이션 점수 대 줄 커버리지, 빈틈 시험 뒤 변화와 주변 변이

a: 줄 커버리지가 모두 95% 이상인 안전 핵심 모듈 10개 중 7개가 뮤테이션 점수 90% 미만이다(점수 = 테스트가 코드 오류를 알아챈 몫). 화살표는 안전 빈틈 15곳을 겨냥한 시험을 더한 뒤의 변화다. b: 핵심 점수는 80.0%에서 83.7%로 올랐고 15곳은 15/15 잡혔지만 이것은 알려진 구멍을 메운 구조상 결과(†)이며, 15곳 밖 변이는 +0.46%p(더 잡힘 2·덜 잡힘 0)만 올라 일반적으로 단단해졌다고 말할 수 없다.

주의: 변이기는 AST 로 직접 만든 것이고 상용 도구와 점수를 비교할 수 없다. 동치·안전 관련 분류는 한 사람의 판단이며 Gemini 2차 분류와 κ 0.46 정도로만 일치한다. 줄 커버리지만 쟀다(분기 아님). B 의 구간 상한은 반증선을 넘어 엄격한 읽기에서는 B 단독 판정 불가다. 모듈별 구간은 E8 측정에 대한 것이다.

실험: E8, E15

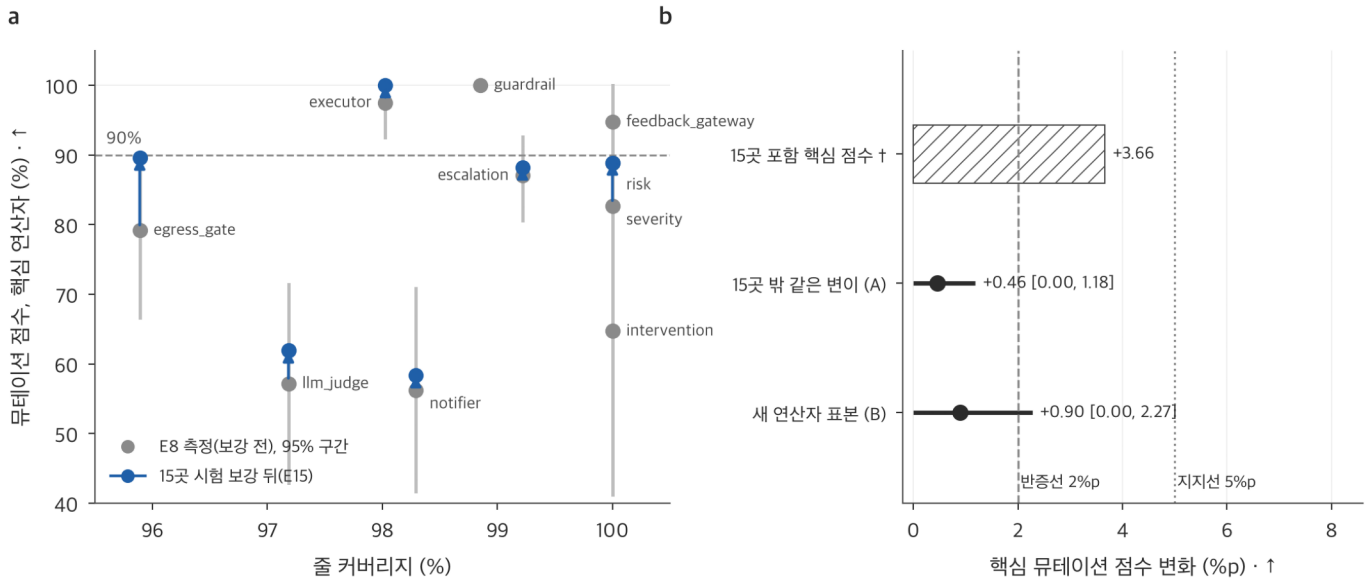
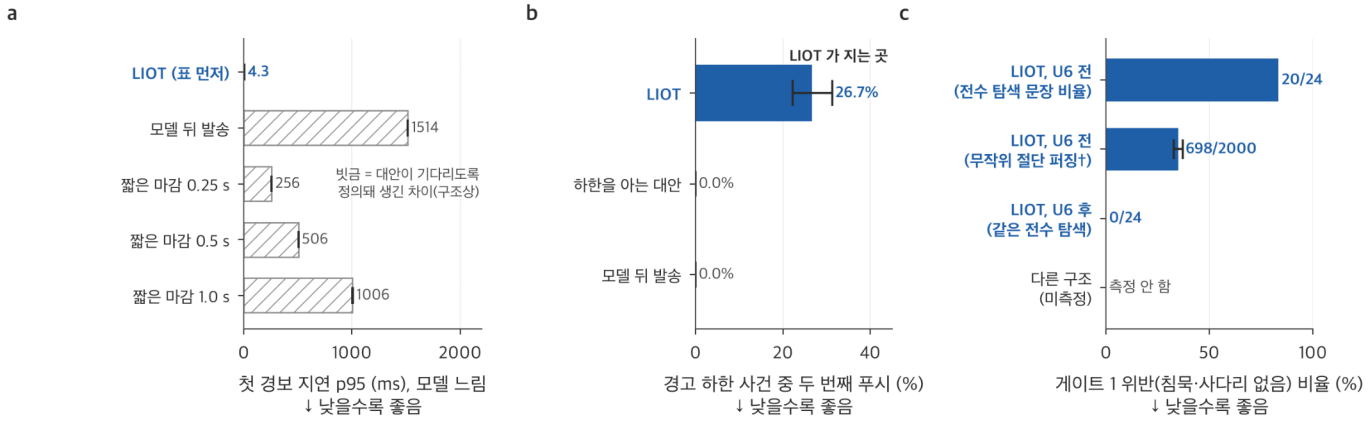


그림 13 (스타일 B 패널 1). 안전: 구조별 첫 경보 지연·두 번째 푸시·재시작 위반(E1/E2/E14)

a: 모델이 느릴 때 LIOT 의 첫 경보 p95 는 4.3 ms이고 모델을 기다리는 대안은 정의상 그만큼 늦다(구조상 결과, LIOT 우위로 읽지 않음). b: 반대로 경고 하한 사건에서 LIOT 는 두 번째 푸시를 26.7% 보내 하한을 아는 대안(0%)보다 푸시가 많다 — LIOT 가 지는 곳. c: 재시작 중간 절단에서 U6 이전 LIOT 는 게이트 1 위반 창이 20/24문장이었고 U6 이후 0/24이다.

주의: 모델 지연·올림 확률 30%·마감은 가정이고 송신기는 가짜이며 부하가 높은 한 대의 기계에서 쟀다. 하드 게이트 위반 0(E2)은 무작위 퍼징 안에서의 0이고 알려진 게이트 1 충돌 두 종류가 있다. c 의 U6 후 값은 kit 재측정이고 읽기 자체가 남지 않는 문장 4개는 복구 불가 빈틈으로 남는다.

실험: E1, E2, E14



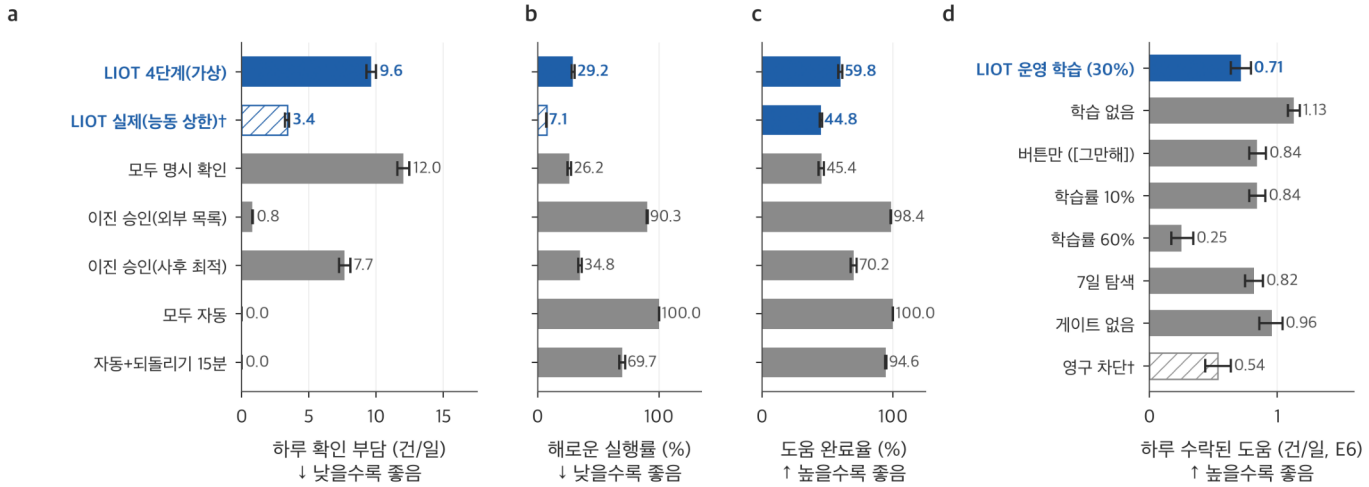
주의: 모든 위반 칸은 LIOT 자신의 이전 버전과의 비교이며 대안 구조는 재시작 시험을 하지 않았다. † 절단 시점을 균등 추출한 값이라 실제 빈도가 아니다.

그림 14 (스타일 B 패널 2). 부담과 도움: 정책별 확인 부담·해로운 실행률·도움 완료율(E3)과 학습 방식별 수락된 도움(E6)

a-c: 오분류 10%에서 LIOT 가상은 확인 부담을 12.0건/일에서 9.6건/일로 줄이지만 해로운 실행률(29.2%)은 모두 명시 확인(26.2%)보다 낮지 않다. LIOT 실제의 부담 3.4건/일과 낮은 해로운 실행률은 땅거미 이상을 침묵시켜 생긴 구조상 결과다. d: 운영 학습의 하루 수락된 도움(0.71)은 버튼만 있는 대안(0.84)보다 낮다.

주의: 거주자 반응은 전부 가정이고 구간은 세트·씨앗 잡음이며 가정의 불확실성은 들어 있지 않다. '이진 승인(사후 최적)'은 이진에게 가장 유리하게 고른 목록이다. 영구 차단은 정의에서 나오는 구조상 결과다. d 의 모아보기 열람 80%는 가정이다.

실험: E3 (policy_table), E6 (pooled)



m = 10%, 지수 피로, 400세트 평균과 95% 구간(a-c, E3) · 씨앗 10개 × 성향 3종 60일(d, E6). † 빗금 = 구조상 결과(LIOT 실제의 낮은 피해·확인은 땅거미 이상 침묵에서 옴).

그림 15 (스타일 B 점수표). LIOT 대 대안 점수표: 비교 축별 승·패·동률·구조상·판정 불가와 'LIOT 가 지는 곳' 전부

a: 연구 질문별 비교 축(행)과 비교 대상(열)마다 칸을 승·패·동률·구조상·판정 불가·기술로 표시했다(승 5, 패 13, 동률 1, 구조상 6, 판정 불가 2, 기술 2). 패 칸이 승 칸보다 많고, 구조상 결과는 승으로 세지 않았다. b: 자료집 V-1 의 'LIOT 가 지는 곳' 28항목을 줄임 없이 모두 적었다.

주의: 승·패는 가정한 거주자·모델·지연 범위 안의 결과이고, 한 칸의 승이 다른 칸의 패를 상쇄하지 않는다. 대안이 구조상 정의된 칸은 구조상으로만 둔다. 칸 분류는 효과 구간과 자료집의 판정 말을 그대로 따랐고 임의로 올리지 않았다. 표에 없는 비교 축은 측정하지 않은 것이다.

실험: E1~E16 (표의 각 칸 수치는 칸 안에 표기)

a

		모두 명시 확인	이진 승인	모델 뒤 발송 ·짧은 마감	곱셈·단일 점수	모델 판정자 (클라우드·상향)	학습 없음 ·버튼만	호출 방식 (최종값·순차)	명세·사전 예측	칸의 근거 수치
Q1 안전	첫 경보 지연 (E1)			구조상						+205 ms
	경고 하한 사건의 두 번째 푸시 (E1)			패						26.7% 대 0
	하드 게이트 위반, 무작위 퍼징 (E2)								구조상	0건
	재시작 중간 절단의 게이트 1, U6 전 (E14)								패	698/2000
	같은 절단 전수 탐색, U6 후 (E14)								기술	침묵 0/24
	사다리 명세 적합 (E7·E14)								패	146건 >1초
	보호자 호출 기준 (E2)							기술		맞교환 184칸
	혼합 보호자 기준 (E14)							승		응답 60초 가정만 6칸
	동시 대 순차 호출 (E7)							판정 불가		27/27 · 24/27
Q2 부담 대 피해	확인 부담, 같은 능동 상한 (E3)	승								-2.40건
	도움 완료, 같은 능동 상한 (E3)	승								+12.5%p
	해로운 실행, 같은 상한, m=10% (E3·E16)	패								+3.2%p
	해로운 실행, 같은 상한, m=0 (E3)	동률								-0.2%p
	해로운 실행, 상한 비일치 등록형 (E3)	구조상								-19.0%p
	LIOT 가상의 해로운 실행, m=10% (E3)	패								더 해로운 세트 68%
	능동 상한이 잃는 도움 (E3)	패								도움 제안 46% 소실
	해로운 실행 대 이진(외부 목록) (E3)		승							29% 대 90%
	해로운 실행 대 이진(사후 최적) (E3)		승							29% 대 35%
Q3 위험 판정	동점 손실, 표 대 곱셈 최선 (E4·E16)				패					32쌍 대 14쌍
	가스가 위험 아래인 설정 (E4·E16)				구조상					표 0 · 곱셈 57%
Q4 적응	학습이 더하는 수락된 도움 (E6)						패			-0.13건/일
	모아보기 만료 규칙 (1), tray0 (E13)						패			0.44 [0.34, 0.56]
	쉬는 기간 7일 대 30일 (E13)						판정 불가			0.042 [0.024, 0.061]
Q5 결정 모델	주입 내성, 로컬 대 클라우드 (E10)					패				0.33 대 0.05
	모델이 하한 위로 올린 일 (E12)					패				0/77
	운영 요약에서 올림 감소 (E5)					구조상				75→4건
Q6 테스트	안전 모듈 뮤테이션 점수, 보강 전 (E8)								패	7/10 모듈 <90%
	빈틈 시험의 15곳 밖 효과 (E15)								패	+0.46%p
	15곳 시험 뒤 핵심 점수 (E15)								구조상	+3.66%p

승 패 동률 구조상 판정 불가 기술

b **LIOT 가 지는 곳 28항목 (자료집 V-1, 전부 표시)**

1. 같은 상한을 씌우면 LIOT 실제의 낮은 피해가 사라진다 (E3-02).
2. 4단계 전부(LIOT 가상)는 모두 명시 확인보다 해롭다 (E3-03).
3. 잔잔 쪽 해로움이 약 20% 만 되어도 liot_real 의 피해 이점이 사라진다 (E3-10).
4. 탭 한 번이 더 쉽게 승인되면 LIOT 가상의 열세가 깊어진다 (E3-11).
5. 위험 점수가 AUC 0.8 쯤만 돼도 단순한 θ 정책이 4단계를 이긴다 (E3-12).
6. 능동 상한이 실제로 잃는 것 (E3-06).
7. 미등록 취약 가구가 있으면 정직한 모델의 최종값 방식이 낫다 (E2-04).
8. LIOT 의 첫 알림 구조는 푸시를 더 보낸다 (E1-03·E1-05).
9. 게이트 1(안전 알림이 늦거나 침묵하지 않는다)과 부딪히는 알려진 문제 두 종류 (E2-03).
10. 느린 송신은 다음 안전 경보를 늦춘다 (E1-04).
11. 사다리는 명세보다 0~5초 늦는다 (E7-01).
12. 방관 효과를 '동시에 호출된 사람 수'로 보면 순차 호출이 낫다 (E7-03).
13. 조회표는 곱셈 점수의 최선 설정보다 등급을 더 뭉갠다 (E4-01).
14. 운영에서는 결정 모델이 위험을 올릴 정보가 사실상 없다 (E5-01·E5-05·E5-06).
15. 보호자 호출에서 모델 상향의 이득이 작다는 결론은 읽기에 달렸다 (E2-05).
16. 추론 누출 1비트 (E2-02).
17. 클라우드 대 로컬의 우열은 가르지 못했다 (E5-02).
18. LIOT 자신의 안전 테스트에 빈틈이 있다 (E8-01~03).
19. 학습은 버튼만 있는 대안보다 더하는 것이 없고 모아보기에서 도움을 잃는다 (E6-01).
20. 30일 게이트가 선호 변화 뒤 첫 재수락을 늦춘다 (E6-02, 사후 기준의 기술 결과).
21. 로컬 판정자는 상황 문장 속 주입에 클라우드보다 훨씬 잘 흔들린다 (E10-01, 사이클 4).
22. 운영 장면에서 모델이 하한 위로 올린 일은 한 번도 없었다 (E12-01·E11-02, 사이클 4).
23. 같은 상한을 건 일치 비교로 H2.1 을 다시 판정하면 LIOT 실제가 더 해롭다 (E16-05, 사후 기준).
24. findings.md 의 모아보기 만료 수정만 적용하면 폰 수락된 도움이 오히려 줄어든다 (E13-02, 사이클 4).
25. 게이트 1 에 걸리는 절단 창이 U6 이전에 실제로 있었다 (E14-03·E14-04, 사이클 4).
26. 곱셈 점수의 최선 설정은 표보다 등급을 더 잘게 나눈다 (E16-02, 사이클 4).
27. 재시작 시점 재동기화 빈틈이 남아 있다 (E14-04·findings, 사이클 4).
28. 빈틈 시험은 그 15곳만 막았고 주변 변이는 거의 더 잡지 못했다 (E15-01·E15-02, 사이클 4).

주의: ① 구조상 결과(빗금)는 비교 결론에 쓰지 않는다. ② 승 칸도 거주자·모델 지연 등 가정 범위 안의 결과다. ③ 같은 상한 비교와 사후 재판정은 사후 기준이며 등록 형태는 판정 불가다. ④ '기술'은 판정이 없는 값이다. ⑤ 칸의 승·패·동률은 그 칸 효과의 95% 구간이 0(또는 해당 기준)과 겹치는지로 정했다.